LAPORAN TES TENGAH SEMESTER

Deep Learning: CNN untuk Citra dan LSTM untuk Data Sekuensial

Anugerah Bintang Matoto Salempang - 672024170 - Deep Learning

Ringkasan

Laporan ini memuat jawaban akhir dua soal TTS. **Soal 1** membandingkan CNN buatan sendiri dengan transfer learning ResNet18 untuk klasifikasi 8 kelas penyakit daun padi (dataset RiceyLeafDisease). **Soal 2** memakai LSTM untuk memprediksi curah hujan harian Jawa Barat satu hari ke depan (dataset curah hujan 460 stasiun, 2020–2025). Seluruh angka berasal dari output notebook final yang dijalankan penulis.

	Soal 1: klasifikasi citra	**Soal 2: peramalan deret waktu**
Data	1.701 citra, 8 kelas	2.192 hari, 460 stasiun (target: rata-rata 453 stasiun)
Model utama	ResNet18 (fine-tuning, 11,18 juta parameter)	LSTM 1 lapis, 64 unit (17.217 parameter)
Pembanding	CNN scratch 4 blok (26,08 juta parameter)	Naive forecast; GRU; Stacked LSTM
Hasil terbaik (data uji)	Akurasi **88,28%**, F1-macro 0,869	RMSE **6,156** mm/hari, MAE 4,727 mm/hari
Pembanding pada data uji	CNN scratch: akurasi 67,19%, F1-macro 0,629	Naive: RMSE 7,698, MAE 5,572
Kesimpulan	Transfer learning unggul sekitar 21 poin	LSTM lebih baik dari naive: RMSE −20,0%, MAE −15,2%

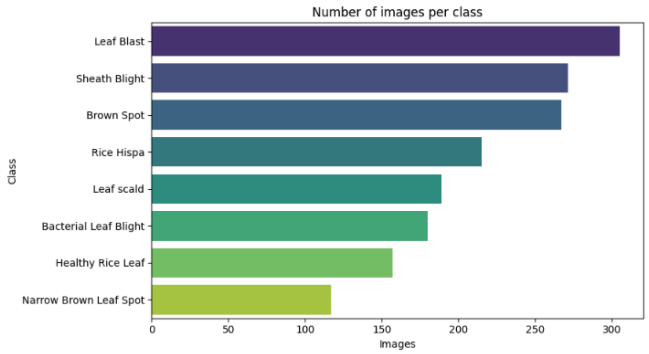
Soal 1. CNN untuk Klasifikasi Citra Penyakit Daun Padi

1.1 Dataset dan persiapan data

Dataset *RiceyLeafDisease* berisi **1.701 citra** daun padi dalam 8 kelas (7 penyakit dan 1 daun sehat). Kelas tidak seimbang: terbanyak *Leaf Blast* (305 citra, 17,93%) dan tersedikit *Narrow Brown Leaf Spot* (117 citra, 6,88%). Data dibagi **70/15/15 secara stratified** (seed 42) sehingga proporsi kelas terjaga di setiap bagian.

Kelas	**Total**	**Train**	**Val**	**Test**
Leaf Blast	305	213	46	46
Sheath Blight	271	190	40	41
Brown Spot	267	187	40	40
Rice Hispa	215	150	32	33
Leaf scald	189	132	28	29
Bacterial Leaf Blight	180	126	27	27

Healthy Rice Leaf	157	110	24	23
Narrow Brown Leaf Spot	117	82	18	17
Total	**1.701**	**1.190 (70%)**	**255 (15%)**	**256 (15%)**



Gambar 1. Jumlah citra per kelas (dataset tidak seimbang).



Gambar 2. Contoh satu citra untuk setiap kelas.

- **Pra-pemrosesan:** citra diubah ke 224×224 dan dinormalisasi dengan mean/std ImageNet.
- **Augmentasi hanya pada data latih.** *Basic:* flip horizontal dan rotasi ±15°. *Strong:* random resized crop (skala 0,7–1,0), flip horizontal dan vertikal, rotasi ±30°, color jitter 0,3. Data validasi dan uji hanya di-resize dan dinormalisasi.
- **Pelatihan:** loss cross-entropy, optimizer Adam, batch 32, 10 epoch per run, seed 42. Bobot dari epoch dengan akurasi validasi tertinggi disimpan dan dipakai untuk evaluasi.

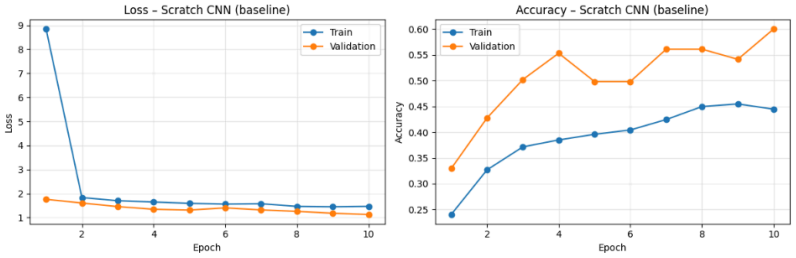
1.2 Arsitektur

CNN scratch memakai **4 blok konvolusi** (Conv 3×3 → BatchNorm → ReLU → MaxPool 2×2) dengan 32→64→128→256 filter. Peta fitur 14×14×256 diratakan (50.176 nilai), lalu melewati *Linear 512*, dropout, dan *Linear 8*. Total **26.084.104 parameter**; sekitar 25,69 juta (98,5%) berada pada lapisan fully connected pertama (50.176 × 512 + 512).

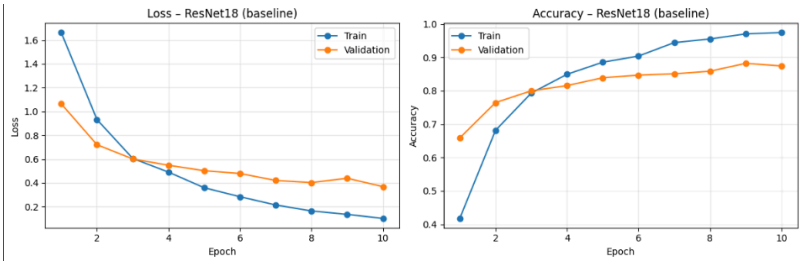
ResNet18 memakai bobot pralatih ImageNet [3,4]; lapisan terakhir diganti Dropout → Linear(512, 8) dan **seluruh lapisan di-fine-tune** dengan learning rate kecil (1e-4). Total **11.180.616 parameter**, lebih sedikit daripada CNN scratch.

```
def build_resnet(dropout=0.5):
  m = models.resnet18(weights=models.ResNet18_Weights.IMAGENET1K_V1)
```

```
m.fc = nn.Sequential(nn.Dropout(dropout), nn.Linear(m.fc.in_features, NUM_CLASSES))
return m.to(device)
```



Gambar 3. Kurva loss dan akurasi CNN scratch (baseline): latih lebih rendah daripada validasi, tanda underfitting.



Gambar 4. Kurva loss dan akurasi ResNet18 (baseline): akurasi latih ±97%, validasi ±88%.

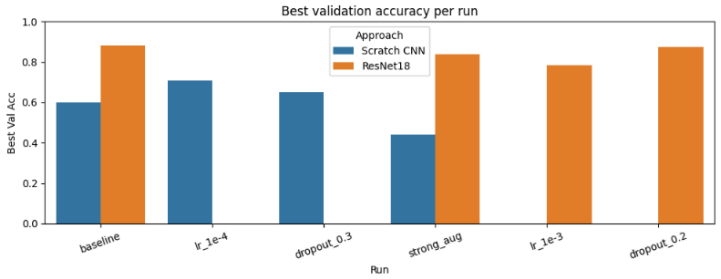
1.3 Eksperimen: learning rate, dropout, augmentasi

Tiga pengaturan diubah **satu per satu** dari baseline masing-masing model. Pemilihan konfigurasi memakai akurasi **validasi** saja data uji baru dipakai di tahap akhir.

Model	Run	LR	Dropout	Augmentasi	Akurasi latih	Akurasi val terbaik
CNN scratch	baseline	1e-3	0,5	basic	44,45%	60,00%
CNN scratch	lr_1e-4	1e-4	0,5	basic	65,88%	**70,98%**
CNN scratch	dropout_0.3	1e-3	0,3	basic	56,97%	65,10%
CNN scratch	strong_aug	1e-3	0,5	strong	31,18%	43,92%
ResNet18	baseline	1e-4	0,5	basic	97,06%	**88,24%**
ResNet18	lr_1e-3	1e-3	0,5	basic	83,11%	78,43%
ResNet18	dropout_0.2	1e-4	0,2	basic	95,80%	87,45%
ResNet18	strong_aug	1e-4	0,5	strong	85,63%	83,92%

- **Learning rate paling berpengaruh.** Pada CNN scratch, lr 1e-3 tidak stabil (loss epoch pertama sangat tinggi); menurunkannya ke 1e-4 menaikkan akurasi validasi 60,00% → 70,98%. Pada ResNet18 justru lr besar merusak bobot pralatih: 88,24% → 78,43%.
- **Dropout:** pada ResNet18 dropout 0,2 vs 0,5 hanya berbeda sekitar 2 citra (87,45% vs 88,24%), jadi tidak ada bukti beda yang berarti.
- **Augmentasi kuat** menurunkan kedua model dalam batas 10 epoch (scratch 43,92%, ResNet18 83,92%) karena tugas menjadi lebih sulit sementara epoch masih sedikit.

- **Konfigurasi terpilih:** CNN scratch lr_1e-4; ResNet18 baseline.

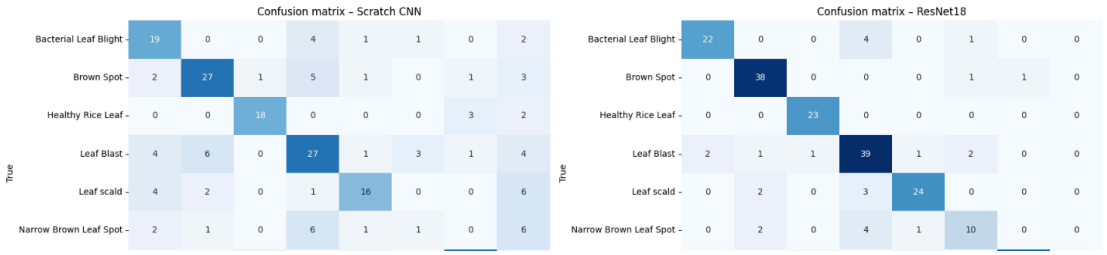


Gambar 5. Akurasi validasi terbaik pada setiap run eksperimen.

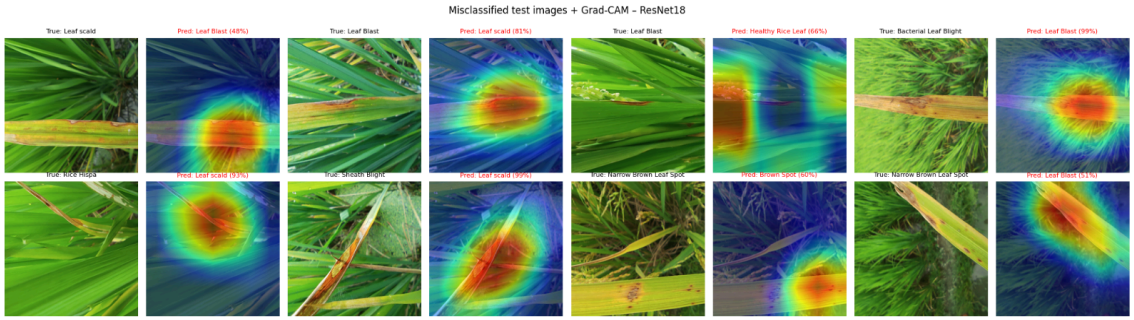
1.4 Evaluasi pada data uji (256 citra)

Model	Akurasi	Precision (macro)	Recall (macro)	F1 (macro)	Salah prediksi
CNN scratch (lr_1e-4)	67,19%	0,646	0,635	0,629	84
ResNet18 (baseline)	**88,28%**	**0,878**	**0,865**	**0,869**	**30**

Perhitungan selisih: 88,28% − 67,19% = **21,09 poin persentase**; F1-macro 0,869 − 0,629 = **0,240**. Akurasi uji ResNet18 (88,28%) hampir sama dengan akurasi validasinya (88,24%), sehingga pemilihan lewat validasi tidak bocor ke data uji.



Gambar 6. Confusion matrix pada data uji: CNN scratch (kiri) dan ResNet18 (kanan).



Gambar 7. Citra salah prediksi ResNet18 dengan Grad-CAM (kiri: citra asli, kanan: area yang diperhatikan model).

1.5 Analisis dan kesimpulan Soal 1

- **Mengapa ResNet18 unggul.** Bobot ImageNet sudah mengenal tepi, tekstur, dan bentuk sehingga hanya perlu disesuaikan, sedangkan CNN scratch belajar semuanya dari 1.190 citra latih. ResNet18 juga lebih hemat parameter (11,18 juta vs 26,08 juta).
- **Overfitting/underfitting.** ResNet18 mencapai akurasi latih ±97% vs validasi ±88%: overfitting ringan hingga sedang yang wajar untuk dataset kecil. CNN scratch baseline justru

underfitting (latih 44% < validasi 60%) akibat kombinasi dropout, augmentasi, dan optimasi yang tidak stabil pada lr 1e-3.

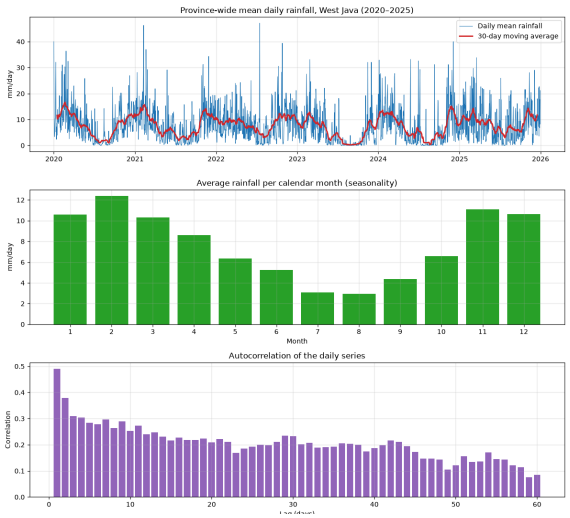
- **Per kelas.** ResNet18 terbaik pada *Sheath Blight* (F1 0,975), *Healthy Rice Leaf* (0,958), dan *Rice Hispa* (0,954); tersulit *Narrow Brown Leaf Spot* (F1 0,645). Pada CNN scratch kelas ini hampir tidak dikenali (F1 0,091). Penyebabnya: datanya paling sedikit (82 citra latih) dan gejalanya mirip *Brown Spot*, *Leaf Blast*, dan *Sheath Blight*.
- **Grad-CAM.** Pada ResNet18, area panas umumnya jatuh pada daun bergejala, jadi model melihat objek yang tepat tetapi gejala antar penyakit mirip; beberapa kesalahan berkeyakinan tinggi (93–99%). Pada CNN scratch peta panas lebih menyebar dan sering menyorot latar belakang.
- **Keterbatasan dan saran.** Satu seed per konfigurasi dan hanya 10 epoch (selisih di bawah ±2% tidak pasti; 1 citra validasi = 0,4%). Saran: menyeimbangkan kelas kecil (class weight/oversampling), lebih banyak epoch dengan scheduler, resolusi lebih tinggi, beberapa seed, dan backbone lain seperti MobileNetV2 atau EfficientNet.

Soal 2. LSTM untuk Peramalan Curah Hujan Harian Jawa Barat

2.1 Dataset dan persiapan data

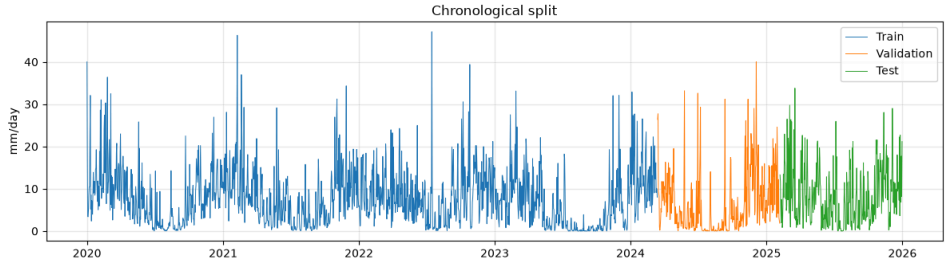
Dataset berisi curah hujan harian (mm) dari **460 stasiun** selama **2.192 hari** (1 Jan 2020 – 31 Des 2025) dalam bentuk matriks (baris = hari, kolom = stasiun). Karena berupa deret waktu, dipakai cabang data sekuensial pada soal. Tugasnya: dari curah hujan **30 hari sebelumnya**, prediksi curah hujan **hari berikutnya**.

Langkah	**Temuan / tindakan**
Cek tanggal	Tidak ada tanggal ganda maupun hari yang terlewat.
Tipe data	739 sel berisi teks `R` di 7 stasiun; bukan angka valid, diubah menjadi NaN.
Data hilang	Total 2,19% sel hilang. 7 stasiun dengan >30% hilang dibuang (tersisa **453 stasiun**).
Target	Rata-rata harian antar stasiun yang melapor (257–453 stasiun per hari): tidak ada hari kosong. Rata-rata 7,65 mm/hari, simpangan baku 6,84, maksimum 47,13.
Alasan memakai rata-rata	Satu stasiun sekitar separuh harinya bernilai 0 mm sehingga sulit diprediksi; rata-rata memberi satu deret yang lebih stabil.
Autokorelasi	Lag 1 = 0,49; lag 2 = 0,38; lag 7 = 0,30 (hubungan sedang, hujan harian cukup acak).



Gambar 8. Data curah hujan: deret harian dengan rata-rata bergerak 30 hari (atas), rata-rata per bulan (tengah), dan autokorelasi (bawah).

Bagian	Periode	Hari	Sampel (window 30 hari)
Train (70%)	1 Jan 2020 – 13 Mar 2024	1.534	1.504
Validation (15%)	14 Mar 2024 – 5 Feb 2025	329	329
Test (15%)	6 Feb 2025 – 31 Des 2025	329	329



Gambar 9. Pembagian kronologis data: train, validation, dan test.

Split kronologis (bukan acak) agar model tidak melihat masa depan. **MinMaxScaler hanya di-fit pada data latih** (0–47,13 mm) untuk mencegah kebocoran data; contoh: 10 mm → (10 − 0)/(47,13 − 0) = 0,212. Sampel dibentuk dengan *sliding window*: input X berbentuk [30, 1] dan target y = hujan hari ke-31, dimasukkan ke bagian split sesuai hari targetnya.

2.2 Baseline naive forecast

Baseline memprediksi **ŷ(t) = y(t−1)** (besok sama dengan hari ini) dan dievaluasi pada hari-hari uji yang sama dengan model LSTM.

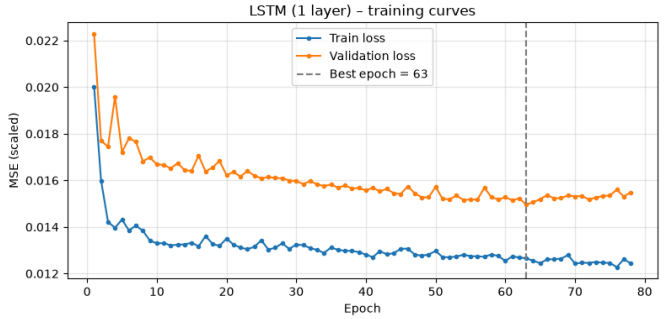
Acuan	Val RMSE	Val MAE	Test RMSE	Test MAE
Naive (besok = hari ini)	7,328	4,571	7,698	5,572
Rata-rata data latih (acuan tambahan)	7,343	5,983	6,864	5,413

2.3 Model LSTM

LSTM memakai tiga gerbang dan satu *cell state*. **Cell state** $C(t) = f(t) \odot C(t-1) + i(t) \odot \tilde{C}(t)$ adalah jalur memori jangka panjang; karena hanya diubah lewat kali dan tambah, gradien dapat mengalir jauh ke belakang tanpa mengecil. **Forget gate** $f(t) = \sigma(W_f \cdot [h(t-1), x(t)] + b_f)$ bernilai 0–1 dan menentukan bagian memori lama yang dibuang (mendekati 0) atau dipertahankan (mendekati 1). **Input gate** menentukan seberapa banyak informasi baru ditulis ke cell state, dan **output gate** menentukan bagian cell state yang dikeluarkan sebagai hidden state.

```
self.rnn  = nn.LSTM(input_size=1, hidden_size=64, batch_first=True)
self.drop = nn.Dropout(0.2);  self.fc = nn.Linear(64, 1)
out, _ = self.rnn(x);  return self.fc(self.drop(out[:, -1, :]))   # langkah waktu terakhir
```

Parameter LSTM: $4 \times (1 \times 64 + 64 \times 64 + 64 + 64) = 17.152$, ditambah Linear $(64 + 1) =$ **17.217**. **Pelatihan:** loss MSE, Adam (lr 3e-3), batch 64, gradient clipping 1,0, *early stopping* (patience 15) dengan bobot epoch terbaik dikembalikan; prediksi dikembalikan ke mm/hari.



Gambar 10. Kurva pelatihan LSTM (seed 42): epoch terbaik 63, berhenti di epoch 78.

Pada seed 42 loss latih turun dari 0,0200 ke 0,0127 dan loss validasi dari 0,0223 ke 0,0150 (epoch terbaik). Loss validasi **tidak naik** meninggalkan loss latih, jadi tidak ada overfitting berarti. Selisih latih–validasi kecil (0,0023; sekitar 5,3 vs 5,8 mm/hari), dan model juga tidak underfitting: RMSE uji 20% lebih baik dari naive.

2.4 Perbandingan LSTM, GRU, dan Stacked LSTM

Ketiganya dilatih dengan kondisi identik dan **3 seed** (42, 43, 44); tabel memuat rata-rata ± simpangan baku. Varian terbaik dipilih dari RMSE **validasi**.

Model	Parameter	Val RMSE	Test RMSE	Test MAE
LSTM 1 lapis	17.217	**5,777 ± 0,011**	**6,156 ± 0,009**	4,727 ± 0,016
GRU 1 lapis [6]	12.929	5,797 ± 0,032	6,228 ± 0,009	4,755 ± 0,003
Stacked LSTM 2 lapis	50.497	5,811 ± 0,011	6,169 ± 0,013	4,713 ± 0,020
Naive baseline	0	7,328	7,698	5,572

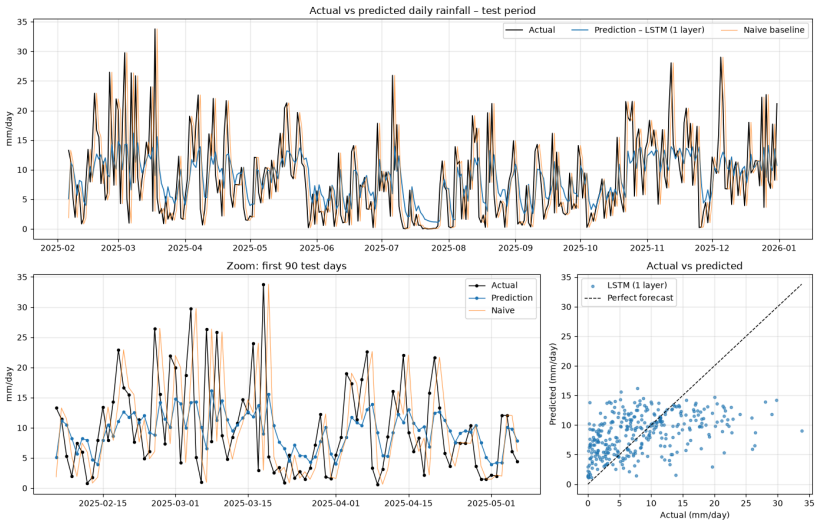
Selisih antar varian kecil (sekitar 0,4% pada validasi) dan urutan LSTM vs GRU tidak konsisten di semua seed, jadi ketiganya pada dasarnya setara. Stacked LSTM, dengan parameter hampir tiga kali

lipat, **tidak** lebih baik; ini menunjukkan batas akurasi ada pada informasi di dalam data, bukan pada ukuran model.

2.5 Evaluasi dan kesimpulan Soal 2

Model (seed 42)	**RMSE (mm/hari)**	**MAE (mm/hari)**
Naive baseline	7,698	5,572
LSTM 1 lapis (terpilih)	**6,158**	**4,749**
GRU 1 lapis	6,216	4,752
Stacked LSTM 2 lapis	6,174	4,690

Perbaikan terhadap naive: RMSE = (7,698 − 6,158)/7,698 = **20,0%**; MAE = (5,572 − 4,749)/5,572 = **14,8%** (rata-rata 3 seed: 20,0% dan 15,2%). RMSE = √(rata-rata kuadrat error) menghukum error besar lebih berat, sedangkan MAE adalah rata-rata kesalahan absolut; keduanya dalam mm/hari.



Gambar 11. Aktual vs prediksi pada data uji: seluruh periode (atas), zoom 90 hari (kiri bawah), dan scatter (kanan bawah).

- **Kesimpulan: LSTM lebih baik daripada baseline naive** pada RMSE maupun MAE, dan keunggulan itu konsisten pada ketiga varian dan semua seed. Garis naive pada grafik selalu tertinggal satu hari dari data aktual sehingga menghasilkan kesalahan ganda pada setiap lonjakan.
- **Keterbatasan:** prediksi jauh lebih halus daripada data aktual (simpangan baku prediksi 3,42 vs aktual 6,81); maksimum prediksi hanya 16,2 mm/hari vs aktual 33,8, dan korelasi 0,43. Model menangkap pola umum tetapi **tidak mampu memprediksi hujan ekstrem**.
- **Saran:** tambahkan fitur kalender (bulan/hari dalam tahun) atau variabel cuaca lain, gunakan loss yang menekankan nilai besar, dan uji pada periode atau horizon lain. Hanya satu periode uji (329 hari) dan 3 seed sehingga selisih kecil antar varian tidak boleh dianggap pasti.

Daftar Pustaka dan Sitasi Dataset

Dataset

[1] Hasan, M., Khatun, S., Raihan, M. A., & Uddin, A. H. (2023). *RiceyLeafDisease: An Extensive Image Dataset of Diverse Rice Leaf Diseases from Different Regions of Bangladesh* (Version 1) [Data set]. Mendeley Data. https://doi.org/10.17632/t46kkgh2yw.1

[2] Saputra, H., Dasanto, B. D., Tarigan, S. D., Santikayasa, I. P., & Darmawan, Y. (2026). *Daily Rainfall Observations from 460 Stations and Flood Event Records across West Java, Indonesia (2020–2025)* (Version 3) [Data set]. Mendeley Data. https://doi.org/10.17632/d7j3s64vvr.3 (lisensi CC BY 4.0). Catatan: teks "How to cite" di berkas README dataset masih menyebut versi 1; laporan ini memakai versi 3, sesuai berkas yang digunakan.

Rujukan metode dan perangkat lunak

[3] He, K., Zhang, X., Ren, S., & Sun, J. (2016). Deep residual learning for image recognition. *Proceedings of the IEEE CVPR*, 770–778.

[4] Deng, J., Dong, W., Socher, R., Li, L.-J., Li, K., & Fei-Fei, L. (2009). ImageNet: A large-scale hierarchical image database. *Proceedings of the IEEE CVPR*, 248–255.

[5] Hochreiter, S., & Schmidhuber, J. (1997). Long short-term memory. *Neural Computation, 9*(8), 1735–1780.

[6] Cho, K., van Merriënboer, B., Gulcehre, C., Bahdanau, D., Bougares, F., Schwenk, H., & Bengio, Y. (2014). Learning phrase representations using RNN encoder–decoder for statistical machine translation. *Proceedings of EMNLP*, 1724–1734.

[7] Selvaraju, R. R., Cogswell, M., Das, A., Vedantam, R., Parikh, D., & Batra, D. (2017). Grad-CAM: Visual explanations from deep networks via gradient-based localization. *Proceedings of the IEEE ICCV*, 618–626.

[8] Paszke, A., et al. (2019). PyTorch: An imperative style, high-performance deep learning library. *Advances in Neural Information Processing Systems, 32*.

Lampiran A. Pernyataan Penggunaan Kecerdasan Buatan (AI)

Alat: Claude (Anthropic), dipakai melalui antarmuka percakapan pada 10–13 Oktober 2026. Penulis tetap bertanggung jawab atas seluruh isi laporan dan kode. Rincian penggunaan:

Tahap	Bantuan AI	Peran dan verifikasi penulis
Debugging	Membantu menemukan dan memperbaiki galat: pemuatan data (path dataset, ZIP bersarang), instalasi pustaka, runtime lokal vs Colab, dan GPU tidak terdeteksi.	Penulis menerapkan perbaikan, menjalankan seluruh notebook sendiri (Soal 1 di Google Colab CPU; Soal 2 di komputer lokal GPU), dan memeriksa tiap output.
Penyuntingan bahasa	Merapikan kalimat dan struktur teks laporan serta komentar kode (bahasa Indonesia dan Inggris).	Penulis membaca dan menyetujui hasil suntingan.

Penyusunan kode	Membantu menyusun kerangka kode notebook (Soal 1 dan Soal 2) berdasarkan ketentuan soal.	Penulis menjalankan, memeriksa, dan mempelajari kode agar dapat menjelaskannya sendiri.
Analisis dan interpretasi	Tidak ada.	Dilakukan sendiri oleh penulis: pembacaan tabel dan grafik hasil, penilaian overfitting/underfitting, perbandingan model, dan kesimpulan.

- **Yang tidak dilakukan AI:** AI tidak melakukan analisis dan interpretasi hasil, dan tidak menjalankan notebook pada data dan perangkat penulis; angka dalam laporan berasal dari output yang dijalankan penulis. AI tidak mengubah ketentuan soal atau data.
- **Pemeriksaan:** kode dijalankan penuh tanpa galat; angka laporan dicocokkan dengan output notebook final; sitasi dataset diambil dari halaman Mendeley Data dan berkas README dataset. Penulis menyadari bahwa hasil dapat sedikit berbeda bila dijalankan ulang (perangkat, seed, urutan data loader).